

~/letra-y-codigo \$

Clase 1

Uso avanzado de IA e instalación de modelos locales

Conceptos, fundamentos y primeras herramientas para correr modelos en tu propia computadora.



Bienvenida



Presentación del docente

Quién soy y desde dónde trabajo el cruce entre IA y humanidades.



Presentación del taller

Qué vamos a hacer y qué te vas a llevar de estas tres clases.



Organización de las clases

Cómo se estructuran los tres encuentros y qué esperar de cada uno.



El proyecto "Letra y código"

¿Qué es?

Un espacio de formación y experimentación sobre inteligencia artificial y programación pensado desde las humanidades y la enseñanza.

Objetivos del proyecto

- Acercar la IA a docentes y estudiantes de humanidades.
- Formar en un uso crítico y práctico de las herramientas informáticas.
- Construir comunidad y recursos abiertos.

Recorrido 2023 – 2026



De los primeros experimentos a un taller consolidado.

Recursos disponibles

Canal de
YouTube

Materiales de
apoyo

Concurso de
programación
para estudiantes
de Letras



1

¿Dónde vive la IA?

Modelos locales y fundamentos

OBJETIVO

Comprender qué significa ejecutar un modelo local y cuáles son sus ventajas y limitaciones.



¿Nube o local?

¿Qué significa que un modelo "corra" en nuestra computadora?



En la nube

Privacidad Tus datos viajan a un servidor externo.

Costos Suscripción o pago por uso.

Velocidad Depende de la conexión y del servicio.

Internet Requiere conexión permanente.

Hardware Requisitos mínimos en tu equipo.



Local



Los datos no salen de tu equipo.



Sin costo por consulta.




Latencia local, según tu máquina.



Funciona sin conexión.



Exige RAM / VRAM suficientes.



RAM y VRAM

Dónde “vive” el modelo mientras lo usás, y cuánta memoria de video hace falta hoy.



RAM

Memoria del sistema

La memoria general que usa el procesador (CPU). Es amplia y barata, pero más lenta para IA. Un modelo puede correr acá, aunque mucho más despacio.



VRAM

Memoria de la placa de video (GPU)

Memoria dedicada y muy rápida de la placa gráfica. Es donde conviene que entre todo el modelo, y el factor que más limita cuál podés correr.

¿Cuánta VRAM para modelos intermedios? (cuantización Q4)

7B – 8B

intermedio liviano

MÍNIMA

8 GB

CÓMODA

12 GB

13B – 14B

intermedio

MÍNIMA

12 GB

CÓMODA

16 GB



El punto clave

Lo ideal es que el modelo entre entero en la VRAM. Si no entra, se reparte con la RAM del sistema y la velocidad se desploma.

Regla práctica (Q4): ~0,6 GB de VRAM por cada mil millones de parámetros, más un extra para el contexto.



La soberanía de los datos



¿Qué datos enviamos?

Al usar ChatGPT o similar, cada consulta viaja a servidores de terceros: textos, documentos, ideas.



GDPR / RGPD (“Reglamento General de Protección de Datos”)

Existen regulaciones varias para el uso de los datos personales por parte de las corporaciones que modelos de la IA



Investigación y datos sensibles

Fuentes inéditas, datos de personas o material confidencial exigen cuidado especial.



Por qué lo local

Muchas instituciones eligen modelos locales para mantener el control sobre su información.



Qué es 421

Cultura

Tecnología

Juegos

Vida real

Rutas

Más+

/ tecnología

¿HOSTEAR LA IA EN TU PROPIA COMPUTADORA? APRENDÉ CÓMO HACERLO

por Mauro Santelli · 15 jun. 2026 · 22 min



- **Menos restricciones:** escritura creativa, juegos de rol, investigación y otros casos donde los filtros pueden resultar limitantes.
- **Asistencia para programar:** autocompletado, generación de tests y documentación integrada al editor (VS Code, Continue.dev, Twinny, etc.).
- **Automatización de tareas:** clasificación de correos, extracción de datos, traducción, formateo y otros flujos repetitivos.
- **Resumen y análisis de documentos:** síntesis de textos, extracción de información de PDFs y producción de borradores.
- **Trabajo con datos sensibles:** procesamiento local de información médica, judicial o financiera sin enviarla a la nube (aunque siempre requiere supervisión humana).

“La pregunta deja de ser “¿es posible la privacidad con los LLMs?” y pasan a ser: “¿qué tanto me interesa?”, “¿cuánto cuesta?” y “¿vale la pena?”. Estas son preguntas que también deberían hacerse las empresas, las universidades y el Estado antes de volverse dependientes de sistemas que se computan en la otra punta del planeta.”



Anatomía básica de un LLM

01

Tokens

Las unidades mínimas de texto que el modelo procesa.

02

Ventana de contexto

Cuánta información puede "tener en mente" a la vez.

03

Temperatura

Controla cuán predecible o creativa es la respuesta.

04

Tamaño del modelo

3B, 7B, 13B... la cantidad de parámetros.

05

Cuantización

Q4, Q6, Q8: comprime el modelo para que entre en menos memoria.

06

Parámetros ↔ RAM / VRAM

Más parámetros exigen más memoria del sistema y de la placa de video.



Instalar Python

Muchas herramientas de IA necesitan Python instalado en la computadora. Hay dos formas principales de hacerlo



Python “solo”

desde `python.org`

- Instala únicamente el lenguaje: lo esencial.
- Descarga liviana y rápida.
- Ideal si querés algo mínimo y ordenado.



Anaconda

un paquete todo-en-uno

- Trae Python + cientos de librerías ya listas.
- Incluye herramientas para datos y ciencia.
- Más pesado, pero “viene con todo”.



Windows: antes de empezar



Windows a veces ya “trae” Python

Puede haber una versión vieja, o un atajo de la Microsoft Store que abre la tienda en lugar de ejecutar Python. Eso confunde a quien recién empieza.



Instalá la versión oficial y actual

Bajala desde python.org. Así trabajás con una versión reciente y evitás sorpresas con la que ya venía en el sistema.



Verificá qué versión tenés

Un solo comando te dice si Python está instalado y cuál es su versión.

 terminal

```
> python --version
```

```
Python 3.12.4
```

```
> _
```



Consejo

Al instalar, marcá la casilla “Add Python to PATH”. Es el paso que más problemas evita.



La variable de entorno PATH

¿Qué es el PATH?

Es la lista de carpetas donde el sistema busca los programas cuando escribís un comando. Es como la agenda de direcciones de la terminal: si Python no figura ahí, no sabe dónde encontrarlo.

Cómo se soluciona



Add Python to PATH

Marcá esta casilla en el instalador. Si te la olvidaste, se puede agregar después a mano.

SIN el PATH configurado

```
terminal  
  
> python  
  
'python' no se reconoce como  
un comando interno o externo.
```

CON el PATH configurado

```
terminal  
  
> python  
  
Python 3.12.4 (funciona)  
  
>>> _
```

Propiedades del sistema

Nombre de equipo

Hardware

Opciones avanzadas

Protección del sistema

Acceso remoto

Para realizar la mayoría de estos cambios, inicie sesión como administrador.

Rendimiento

Efectos visuales, programación del procesador, uso de memoria y memoria virtual

Configuración...

Perfiles de usuario

Configuración del escritorio correspondiente al inicio de sesión

Configuración...

Inicio y recuperación

Inicio del sistema, errores del sistema e información de depuración

Configuración...

Variables de entorno...

Aceptar

Cancelar

Aplicar

Variables de entorno

Variables de usuario para mariano

Variable	Valor
ChocolateyInstall	C:\ProgramData\chocolatey
ChocolateyLastPathUpdate	134260892001151518
OLLAMA_MODELS	E:\OllamaModels
OneDrive	C:\Users\mariano\OneDrive - UBA
OneDriveCommercial	C:\Users\mariano\OneDrive - UBA
Path	C:\Users\mariano\AppData\Local\Microsoft\WindowsApps;C...
TEMP	C:\Users\mariano\AppData\Local\Temp

Nueva...

Editar...

Eliminar

Variables del sistema

Variable	Valor
ComSpec	C:\WINDOWS\system32\cmd.exe
DriverData	C:\Windows\System32\Drivers\DriverData
NUMBER_OF_PROCESSORS	12
OS	Windows_NT
Path	C:\WINDOWS\system32;C:\WINDOWS;C:\WINDOWS\System3...
PATHEXT	.COM;.EXE;.BAT;.CMD;.VBS;.VBE;.JS;.JSE;.WSF;.WSH;.MSC
PROCESSOR_ARCHITECTU...	AMD64

Nueva...

Editar...

Eliminar

Aceptar

Cancelar

Editar variable de entorno

%USERPROFILE%\AppData\Local\Microsoft\WindowsApps

C:\Users\mariano\AppData\Local\Programs\Antigravity\bin

C:\Users\mariano\AppData\Local\Python\bin

C:\Users\mariano\AppData\Local\Programs\Microsoft VS Code\...

C:\Users\mariano\AppData\Local\Programs\Ollama

C:\Users\mariano\AppData\Local\Microsoft\WinGet\Packages\G...

C:\Program Files\Tesseract-OCR

C:\Users\mariano\AppData\Local\Python\pythoncore-3.14-64

C:\Users\mariano\AppData\Local\Python\bin

C:\Users\mariano\AppData\Local\Python\pythoncore-3.14-64\S...

Nuevo

Modificar

Examinar...

Eliminar

Subir

Bajar

Editar texto...

Aceptar

Cancelar

BLOQUE



Instalar y utilizar un modelo local

OBJETIVO

Comprender el funcionamiento básico de Ollama y el uso de la terminal.

2



La terminal

¿Qué es una CLI?

Una interfaz de línea de comandos: escribimos órdenes en texto en lugar de hacer clic.

¿Por qué sigue vigente?

Es rápida, precisa y la puerta de entrada a muchísimo software de IA.

Navegación básica

Movernos entre rutas y carpetas del sistema con unos pocos comandos.



terminal

```
$ pwd
```

```
/home/usuario
```

```
$ cd proyectos
```

```
$ dir
```

```
modelos/    datos/    notas.md
```

```
$ _
```

cd cambiar de carpeta **dir** listar contenido



Windows PowerShell



¿Qué es PowerShell?

La terminal moderna de Windows: una consola donde escribimos comandos para controlar el sistema, instalar herramientas y ejecutar programas como Ollama.

Es la sucesora del viejo “símbolo del sistema” (CMD), con muchas más capacidades.

Abrirla en la carpeta que estás explorando

1

Clic derecho en un espacio vacío de la carpeta y elegí “Abrir en el terminal”.

Windows 11 · abre Windows Terminal, que usa PowerShell por defecto.

2

En la barra de direcciones del explorador, escribí powershell y Enter.

Se abre directamente en esa carpeta, sin navegar a mano.

```
> Este equipo > Documentos > powershell
```



Ollama



¿Qué es Ollama?

Una herramienta que permite descargar y ejecutar modelos de lenguaje directamente en tu computadora, con un solo comando.

El estándar de facto

- Instalación simple, sin configuraciones complejas.
- Un catálogo enorme de modelos abiertos listos para usar.
- Misma experiencia en Windows, macOS y Linux.
- Puede ser usado desde otras aplicaciones o la línea de comandos



Demo: comandos de Ollama

```
$ ollama pull
```

Descarga un modelo desde el catálogo.

```
$ ollama run
```

Ejecuta un modelo y abre el chat.

```
$ ollama list
```


Muestra los modelos ya descargados.

```
$ ollama ps
```

Ver qué modelos están corriendo ahora.

```
$ ollama rm
```

Elimina un modelo del disco.



Modelos vs. recursos

Comparamos distintos modelos en vivo y observamos cómo cambia el consumo de memoria y la velocidad según su tamaño y cuantización.



Modelfile

¿Qué es un Modelfile?

Un archivo de texto que define cómo se comporta un modelo derivado.

Personalización

A través de un system prompt le damos una identidad o rol fijo.

Modelo derivado

Con un ejemplo sencillo creamos nuestra propia variante de un modelo base.

Modelfile

```
FROM llama3
```

```
SYSTEM """
```

```
Sos un tutor de literatura  
que responde en español  
de forma clara y breve.
```

```
"""
```

```
$ ollama create tutor -f Modelfile
```

```
$ ollama list
```

```
$ ollama run [nombre del modelo creado]
```



MODELOS LOCALES

Modelos gratuitos para empezar

Todos se descargan con Ollama y funcionan bien en equipos modestos. Elegí la versión (tamaño) según tu memoria.

META

3B-8B · 8-16 GB

Llama 3

El todoterreno más usado. Buen equilibrio general y versiones muy chicas.

```
$ ollama pull llama3.2
```

MISTRAL AI

7B · ~8 GB

Mistral

Liviano y muy rápido. Ideal cuando el hardware es justo.

```
$ ollama pull mistral
```

GOOGLE

4B-12B · 8-16 GB

Gemma 3

Fuerte en varios idiomas, incluido el español. Chico a mediano.

```
$ ollama pull gemma3
```

ALIBABA

4B-8B · 8-16 GB

Qwen 3

Excelente calidad por tamaño y muy bueno en multilingüe.

```
$ ollama pull qwen3
```

MICROSOFT

~14B · 16 GB

Phi-4

Chico pero capaz: razona muy bien para su tamaño.

```
$ ollama pull phi4
```

DEEPSEEK

7B-14B · 8-16 GB

DeepSeek-R1

Modelo de razonamiento: “piensa” paso a paso antes de responder.

```
$ ollama pull deepseek-r1
```

El ecosistema cambia rápido: nombres, versiones y tamaños se actualizan seguido. Revisá ollama.com para lo más reciente.

BLOQUE



El ecosistema de trabajo

OBJETIVO

Presentar algunas herramientas para el desarrollo con IA.

3



GitHub



¿Qué es GitHub?

Una plataforma para alojar y compartir código de forma pública o privada.



¿Qué es un repositorio?

La carpeta de un proyecto, con todo su código, historia y archivos.



¿Cómo se descarga?

Clonando el repositorio o bajando un ZIP desde su página.



¿Por qué es abierto?

Gran parte del software de IA es libre: se puede leer, auditar y mejorar.

Ejemplos:

[Ollama](#)

[AnythingLLM](#)

 markitdown Public

Watch 540 Fork 12.2k Star 169k

main 11 Branches 21 Tags

Go to file T

Add file

<> Code

 guoyu-wang and Guoyu Wang fix: handle PPTX SVG images without a rasterized f... 2e42a01 · 2 days ago 313 Commits

.devcontainer	feat: enable Git support in devcontainer (#136)	2 years ago
.github	Bump actions/checkout from 4 to 5 (#1394)	11 months ago
packages	fix: handle PPTX SVG images without a rasterized fallback (#2...	2 days ago
.dockerignore	feat(docker): improve dockerfile build (#220)	last year
.gitattributes	[MS] Extend table support for wide tables (#1552)	5 months ago
.gitignore	[MS] Update PDF table extraction to support aligned Markdo...	6 months ago
.pre-commit-config.yaml	Initial commit.	2 years ago
CODE_OF_CONDUCT.md	CODE_OF_CONDUCT.md committed	2 years ago
Dockerfile	feat(docker): improve dockerfile build (#220)	last year

About

Python tool for converting files and office documents to Markdown.

autogen autogen-extension langchain markdown microsoft-office openai pdf

Readme MIT license Code of conduct Security policy Activity Custom properties 169.0k stars 540 watching 12.2k forks



VS Code



¿Qué es un IDE?

Un entorno de desarrollo integrado: el lugar donde escribimos, organizamos y ejecutamos nuestro código.

Componentes principales



Editor

Donde escribimos y editamos el código.



Explorador de archivos

El árbol de carpetas del proyecto.



Terminal integrada

Una consola dentro del propio editor.



Extensiones

Complementos que amplían sus capacidades.



AnythingLLM



Interfaz gráfica

Una app visual para usar modelos locales o API keys sin depender de la terminal.



Conexión con Ollama

Se apoya en Ollama para ejecutar el modelo por detrás.



Endpoint local

Se configura apuntando al endpoint que expone Ollama en tu equipo.



RAG con un PDF

Demostración: le damos un PDF y el modelo responde sobre su contenido.



API y endpoint local

API

Una "puerta" definida para que dos programas se comuniquen entre sí.

API Key

Una clave que identifica y autoriza a quien hace las consultas.

Endpoint

La dirección concreta a la que se envían esas consultas.

Cómo otras aplicaciones se comunican con Ollama

Aplicación



API / endpoint



Ollama



Modelo LLM



Síntesis del ecosistema



GitHub

Descargamos el software



VS Code

Nuestro entorno de trabajo



Ollama

Ejecuta el modelo local



Modelo LLM

El motor que responde



AnythingLLM y otras apps

Usan el modelo



Las próximas clases

CLASE 2



Agentes de IA

Cómo los modelos pueden planificar acciones, utilizar herramientas y ejecutar tareas complejas.

CLASE 3



Programación asistida con IA

Vibecoding: desarrollar aplicaciones completas usando modelos de lenguaje desde VS Code.