

Agentes autónomos

Qué son, cómo funcionan y cuándo convienen
en Humanidades y Ciencias Sociales

Pablo D. Zdrojewski

Facultad de Filosofía y Letras · Universidad de Buenos Aires

29 de julio de 2026

- Distinguir
- Abrir la caja
- Panorama en Humanidades y Ciencias Sociales
- Usos aplicados
- Límites, riesgos y ética
- Demostraciones en vivo

El modelo

- procesa *tokens* dentro de una ventana de contexto;
- se ejecuta en la nube o localmente;
- responde según instrucciones y parámetros.

El ecosistema

- una API (*interfaz de programación de aplicaciones*) conecta sistemas;
- la RAG (*generación aumentada por recuperación*) incorpora información recuperada;
- la terminal permite ejecutar herramientas.

El paso de hoy: convertir ese modelo en parte de un sistema capaz de **decidir y actuar**.

¿Quién decide el próximo paso?

Humano

Usa una herramienta y decide cada acción.

Flujo

Ejecuta una secuencia diseñada de antemano.

Agente

Elige acciones según el objetivo y lo observado.

1. Distinguir **asistente**, **workflow** y **agente autónomo**.
2. Explicar el papel de **tools**, **skills**, **memoria**, **loop** y **harness**.
3. Reconocer cuándo conviene un flujo fijo y cuándo hace falta decisión autónoma.
4. Identificar usos valiosos y usos riesgosos en la propia disciplina.
5. Evaluar críticamente un resultado en lugar de aceptarlo por defecto.

Bloque 1

≈80 min

- Distinguir: automatización, workflow y agente
- Abrir la caja: componentes de un agente
- Panorama en Humanidades y Ciencias Sociales

Bloque 2

≈90 min

- Usos aplicados en profundidad
- Límites, riesgos y ética
- Demostraciones en vivo y cierre

Pausa de 10 minutos entre bloques.

- Distinguir
- Abrir la caja
- Panorama en Humanidades y Ciencias Sociales
- Usos aplicados
- Límites, riesgos y ética
- Demostraciones en vivo

Automatizar no es lo mismo que delegar decisiones

Automatización

El humano fija de antemano la secuencia $A \rightarrow B \rightarrow C$:

- repetible y predecible;
- fácil de auditar.

Agencia

El humano fija el objetivo; el sistema decide:

- qué información necesita;
- qué acción ejecutar;
- si corrige o reintenta;
- cuándo terminó.

Tres modos de ayuda, tres grados de control

El archivero

Ejecuta instrucciones exactas.
No decide nada.

El ayudante

Recibe un objetivo amplio,
trabaja solo y reporta pasos.

El colega

Decide métodos, fuentes y
criterios; determina cuándo
terminó.

La novedad no es tener herramientas, sino que el sistema **elige** cuándo y cómo usarlas.

Una escala, no una frontera absoluta

- 1 Chat / respuesta**
El humano indica cada paso; un intercambio y termina.
- 2 Workflow fijo**
Secuencia diseñada de antemano; misma ruta siempre.
- 3 Workflow con IA (*inteligencia artificial*)**
Un paso interpreta con un modelo, pero la ruta sigue prefijada.
- 4 Agente acotado**
Elige acciones dentro de un dominio y un objetivo definidos.
- 5 Agente abierto**
Redefine su propia ruta según lo que va encontrando.

La pregunta no es si tiene IA, sino qué decisiones quedan abiertas en la ejecución.

Agente autónomo

Sistema que recibe un **objetivo de alto nivel**, observa un entorno, selecciona y ejecuta acciones mediante herramientas, evalúa los resultados y repite hasta cumplir un criterio de terminación.

Debe poder decidir

- el próximo paso;
- la herramienta pertinente;
- si el resultado alcanza.

No necesita necesariamente

- aprender de modo permanente;
- operar sin ningún límite;
- ser multiagente.

Chat y agente: la diferencia está en la arquitectura

	Chat	Agente
Impulso	espera una petición	persigue un objetivo
Control	el humano indica cada paso	el sistema elige acciones
Entorno	conversación y adjuntos	aplicaciones, archivos, web, LMS (<i>sistema de gestión del aprendizaje</i>)
Duración	un intercambio	múltiples pasos y reintentos
Finalización	la decide el humano	aplica un criterio de éxito
Riesgo	respuesta errónea	acción errónea y efectos acumulativos

Actividad: ¿workflow o agente?

1. Copiar respuestas de un formulario a una planilla y enviar un acuse.
2. Aplicar una rúbrica y derivar a revisión humana las entregas dudosas.
3. Investigar, decidir nuevas búsquedas y detenerse cuando la evidencia converja.
4. Construir un aula desde el programa, tratar faltantes y verificar el resultado.

Actividad: ¿workflow o agente?

1. Copiar respuestas de un formulario a una planilla y enviar un acuse.
2. Aplicar una rúbrica y derivar a revisión humana las entregas dudosas.
3. Investigar, decidir nuevas búsquedas y detenerse cuando la evidencia converja.
4. Construir un aula desde el programa, tratar faltantes y verificar el resultado.

1. Workflow clásico

Actividad: ¿workflow o agente?

1. Copiar respuestas de un formulario a una planilla y enviar un acuse.
2. Aplicar una rúbrica y derivar a revisión humana las entregas dudosas.
3. Investigar, decidir nuevas búsquedas y detenerse cuando la evidencia converja.
4. Construir un aula desde el programa, tratar faltantes y verificar el resultado.

1. Workflow clásico
2. Workflow con IA

Actividad: ¿workflow o agente?

1. Copiar respuestas de un formulario a una planilla y enviar un acuse.
2. Aplicar una rúbrica y derivar a revisión humana las entregas dudosas.
3. Investigar, decidir nuevas búsquedas y detenerse cuando la evidencia converja.
4. Construir un aula desde el programa, tratar faltantes y verificar el resultado.

1. Workflow clásico
2. Workflow con IA
3. Agente abierto

Actividad: ¿workflow o agente?

1. Copiar respuestas de un formulario a una planilla y enviar un acuse.
2. Aplicar una rúbrica y derivar a revisión humana las entregas dudosas.
3. Investigar, decidir nuevas búsquedas y detenerse cuando la evidencia converja.
4. Construir un aula desde el programa, tratar faltantes y verificar el resultado.

1. Workflow clásico
2. Workflow con IA
3. Agente abierto
4. Agente acotado

Actividad: ¿workflow o agente?


1. Copiar respuestas de un formulario a una planilla y enviar un acuse.
2. Aplicar una rúbrica y derivar a revisión humana las entregas dudosas.
3. Investigar, decidir nuevas búsquedas y detenerse cuando la evidencia converja.
4. Construir un aula desde el programa, tratar faltantes y verificar el resultado.

1. Workflow clásico
2. Workflow con IA
3. Agente abierto
4. Agente acotado

El caso 2 sería un agente si pudiera decidir cómo investigar, pedir información o reintentar. La clasificación depende de la arquitectura, no del tema.

- Distinguir
- Abrir la caja
- Panorama en Humanidades y Ciencias Sociales
- Usos aplicados
- Límites, riesgos y ética
- Demostraciones en vivo

Un agente no es solo un modelo



Una tool hace algo concreto

- buscar un archivo;
- leer una página;
- consultar una planilla;
- crear una actividad;
- enviar un correo.

El agente necesita saber

- qué hace;
- qué entradas acepta;
- qué devuelve;
- qué permisos requiere;
- qué efectos produce.

Una descripción ambigua de una herramienta produce acciones técnicamente válidas pero conceptualmente equivocadas.

Skill

Paquete reutilizable de **instrucciones, criterios, recursos y, a veces, scripts** que le enseña al agente a ejecutar bien una clase de tarea.

Tool

- *crear tarea en Moodle;*
- capacidad atómica;
- interfaz con un sistema.

Skill

- *diseñar una tarea evaluable;*
- procedimiento y criterios;
- conocimiento institucional.

En una skill, la description es el gatillo

El agente no lee la skill entera para decidir si le sirve: lee **solo la description**. Por eso no describe *qué es*, sino **cuándo usarla**.

// debil: no dice cuando dispararse

```
description: "Herramienta para  
trabajar con documentos."
```

// buena: enumera disparadores

```
description: "Usar cuando haya que  
leer, unir, dividir u OCR de un  
PDF, o producir uno."
```

Buena parte de la efectividad se juega ahí: si no lista los verbos y contextos que la activan, el agente nunca la carga.

Memoria: estado de trabajo, no «recuerdo humano»

De trabajo

- objetivo actual;
- plan;
- resultados recientes.

Persistente


- decisiones previas;
- preferencias;
- progreso entre sesiones.

Externa

- archivos;
- bases de datos;
- registros de ejecución.

Para tareas largas, un buen registro de estado suele ser más fiable que una conversación cada vez más extensa.

El loop convierte una respuesta en una conducta



Pregunta en cada vuelta

Dado el objetivo y lo que acaba de ocurrir, ¿qué acción conviene ejecutar ahora?

El loop necesita salidas y límites claros

Condiciones de terminación

- objetivo verificado;
- ninguna acción útil disponible;
- se alcanzó el límite;
- se requiere decisión humana.


Límites de seguridad

- máximo de pasos;
- presupuesto de tiempo o dinero;
- dominios y herramientas permitidos;
- acciones que exigen aprobación.

Harness: la infraestructura que hace posible al agente

Harness (arnés de ejecución)

Sistema que envuelve al modelo: ensambla el contexto, expone herramientas, ejecuta el loop, mantiene estado, aplica permisos, registra acciones y devuelve el resultado.



Cada componente cumple una función distinta

Componente	Pregunta	Ejemplo en Moodle
Modelo	¿qué conviene hacer?	decidir si falta una sección
Tool	¿qué acción puede ejecutar?	crear sección, subir archivo
Skill	¿cómo se hace bien?	reglas para estructurar un aula
Memoria	¿qué ocurrió y qué falta?	lista de unidades ya creadas
Loop	¿qué sigue tras el resultado?	revisar, corregir o terminar
Harness	¿cómo se organiza y controla?	navegador, permisos, logs, límites

- Distinguir
- Abrir la caja
- Panorama en Humanidades y Ciencias Sociales
- Usos aplicados
- Límites, riesgos y ética
- Demostraciones en vivo

1. **Constitución y limpieza de corpus** — reunir, normalizar, deduplicar materiales.
2. **Transcripción y anotación** — pasar audio a texto y etiquetar según un esquema.
3. **Análisis cualitativo asistido** — codificación temática sobre entrevistas o documentos.
4. **Gestión y síntesis bibliográfica** — buscar, filtrar y contrastar literatura.
5. **Apoyo a la docencia** — tutoría, retroalimentación y armado de materiales.

En todos los casos, el resultado es un punto de partida verificable, no un producto final.

Tres tareas donde aporta y tres donde conviene abstenerse

Aporta valor

- normalizar un corpus heterogéneo;
- preparar una primera pasada de codificación para revisión humana;
- mapear literatura y detectar vacíos.

Riesgoso o inconveniente

- fijar la calificación final de un estudiante;
- interpretar sin situar histórica ni culturalmente;
- subir datos personales sensibles a un servicio externo.

Regla práctica: usar la **menor autonomía suficiente** para la tarea y su riesgo.

¿Cuándo usar cada arquitectura?

Si la tarea es...	Ejemplo	Arquitectura	Motivo
estable y repetitiva	copiar formulario y avisar	workflow	control
estable con texto variable	extraer datos de programas	workflow con IA	interpretación
abierta pero acotable	construir un aula	agente acotado	adaptación
exploratoria	revisión bibliográfica	agente supervisado	búsqueda iterativa
de alto impacto	calificación final	apoyo, no autonomía plena	responsabilidad

Pausa

10 minutos

- Distinguir
- Abrir la caja
- Panorama en Humanidades y Ciencias Sociales
- Usos aplicados
- Límites, riesgos y ética
- Demostraciones en vivo

Corpus

- reunir fuentes de formatos dispares;
- normalizar metadatos y codificación;
- deduplicar y detectar faltantes.

Transcripción y anotación

- audio a texto con marcas de hablante;
- etiquetado según un esquema dado;
- marcado de pasajes dudosos.

Límite honesto: la transcripción automática yerra en solapamientos, nombres propios y variedades no estándar. Exige revisión de una muestra y cuidado con datos de sujetos.

Encargo

Aplicá este manual de códigos a las entrevistas, registrá la evidencia textual, marcá ambigüedades y proponé revisiones del *codebook* sin alterar los datos.

Skill central

- unidad de análisis;
- reglas de inclusión y exclusión;
- ejemplos y contraejemplos.

Loop

- codificar una muestra;
- detectar conflicto;
- consultar el manual;
- marcar incertidumbre o escalar.

Encargo

Revisá trabajos sobre evaluación con IA en Humanidades, delimitá criterios, contrastá resultados y entregá una matriz de evidencia con enlaces verificables.

Decisiones autónomas

- reformular búsquedas;
- seguir citas pertinentes;
- descartar fuentes;
- buscar evidencia contraria.

Controles indispensables

- no inventar referencias;
- separar hallazgo de inferencia;
- conservar DOI (*identificador de objeto digital*) o URL;
- revisión humana de la síntesis.

Objetivo

Evaluar un análisis del estudiante, diagnosticar el primer punto de divergencia y ofrecer una pista graduada, sin revelar de entrada la solución.

Tools

- leer la estructura del analizador;
- consultar ejemplos autorizados;
- comparar constituyentes y relaciones.

Decisiones

- qué error atender primero;
- qué nivel de pista ofrecer;
- cuándo derivar al docente.

- Distinguir
- Abrir la caja
- Panorama en Humanidades y Ciencias Sociales
- Usos aplicados
- Límites, riesgos y ética
- Demostraciones en vivo

1. **Evidencia fabricada:** referencias, citas o datos inexistentes.
2. **Descontextualización:** categorías aplicadas sin historia ni situación.
3. **Sesgo:** reproducción de desigualdades en corpus y criterios.
4. **Opacidad:** difícil reconstruir la cadena de decisiones.
5. **Privacidad:** datos de estudiantes, entrevistas y materiales sensibles.
6. **Desplazamiento del juicio:** automatizar aquello que constituye el aprendizaje.

Caso documentado: un abogado presentó un escrito con jurisprudencia inventada por un sistema de IA —nombres, citas y números de causa inexistentes— y fue sancionado por el tribunal.

Análogo académico:

- el agente atribuye un «artículo seminal» a un autor que nunca lo escribió;
- citarlo sin verificar constituye fraude académico.

Pregunta para la sala

¿Qué verificación es imprescindible en su disciplina y no puede delegarse?

Ejemplo

Ante «resumí las teorías sobre el trabajo doméstico», el sistema prioriza autores del Norte Global y omite tradiciones y voces del Sur.

¿Por qué ocurre? Los rankings priorizan citaciones, y ciertas tradiciones están sobrerrepresentadas en las bases dominantes. El agente reproduce esa desigualdad sin saberlo.

Mitigación parcial: pedir explícitamente fuentes y tradiciones subrepresentadas, y auditar la muestra.

Preguntas abiertas

- ¿herramienta o coautoría?
- ¿quién responde por la decisión 37 de 50?
- ¿qué se declara y cómo?

En evaluación de estudiantes

- transparencia sobre el uso;
- no delegar la nota final;
- usar IA para que piensen más, no menos.


Plantilla de declaración metodológica

«Se utilizó [sistema] para [tarea]. Operó bajo supervisión humana. Todos los datos y citas fueron verificados mediante [método]. No se usaron datos personales identificables en servicios de terceros.»

Levantar tarjeta **verde** (aceptable), **amarilla** (precaución) o **roja** (inaceptable); luego, dos o tres argumentan.

1. Transcribir entrevistas anonimizadas y revisar una muestra del 10 %.
2. Subir transcripciones con nombres reales a un servicio en la nube.
3. Generar 20 variaciones estilísticas de un poema para discutir en clase.
4. Publicar como «modelo científico» la predicción de una elección futura.
5. Mapear 500 artículos en conceptos clave; el análisis lo escribe el humano.

De riesgos a guardas: ajustar la autonomía al impacto



Dónde interviene el humano y cómo verificar

Antes

- autorizar el plan;
- definir límites;
- seleccionar fuentes.

Durante

- aprobar acciones críticas;
- resolver ambigüedad;
- intervenir ante alertas.

Después

- auditar una muestra;
- validar el resultado;
- corregir políticas.

Verificar es abrir la fuente: si el agente dice «según la página 45», ir a la página 45.

- Distinguir
- Abrir la caja
- Panorama en Humanidades y Ciencias Sociales
- Usos aplicados
- Límites, riesgos y ética
- Demostraciones en vivo

En las cuatro, observar lo mismo:

- qué información consulta el sistema;
- **quién decide** la próxima acción;
- qué conserva entre pasos;
- cuándo se detiene o pide ayuda.

Usar datos ficticios o un entorno de prueba. El valor está en la trazabilidad, no en operar sobre información real de personas.

Demo 1 — El mismo workflow, con y sin IA

Qué se muestra

- una ficha a partir de un programa, primero a mano;
- luego con un paso de IA que interpreta el texto.

Qué observar

- cambia: tiempo, pasos, esfuerzo;
- no cambia: quién controla la ruta;
- aparece: la verificación.

[EN VIVO / CAPTURA: a mano vs. con IA; mostrar una alucinacion y verificar]

Demo 2 — Razonamiento y selección de herramientas



El punto

- la elección de herramienta **no está programada**;
- la decide el modelo según la consulta;
- ante otra consulta, elige distinto.

[CAPTURA: el modelo elige buscador / calculadora / lector segun la consulta]

Demo 3 — Agentes vs. skills

El agente carga **solo la *description*** de cada skill (nivel 1). Recién cuando la tarea coincide, abre el cuerpo (nivel 2) y sus recursos (nivel 3): *progressive disclosure*.

La skill es la herramienta; el **agente** decide cuándo y cómo usarla.

```
// skills disponibles (nivel 1)
docx    crear/editar Word
pdf     leer/unir/dividir/OCR
xlsx    planillas y formulas
consignas  sintaxis (gb4e)
```

[EN VIVO: pedir una tarea y ver que se despliega solo el cuerpo del skill pertinente]

Qué es

Un agente que, a partir del programa en PDF, arma y llena el aula operando el navegador con rol de **profesor con edición**. Sin API ni permisos de administrador.

Planifica y ejecuta

- lee el programa y crea secciones;
- nombra, resume y agrega contenidos;
- informa la bibliografía no volcada.

Volver a lo visto

- tools semánticas vs. skill del aula;
- loop, memoria y harness;
- recaudos y supervisión.

Demo 4 — Corrida supervisada

Qué mostrar

1. estado inicial del aula;
2. lectura y tool propuesta;
3. aprobación y cambio visible;
4. reporte final con `finish`.

```
> read_syllabus(programa.pdf)
> list_sections() // aula vacia
> create_section("U1")
> add_page("U1", ...)
> ... // aprobacion humana
> finish() // 12 pasos, ok
```

`add_page` no es idempotente: repetir la corrida duplica recursos. Usar un curso descartable o mostrar `run.log`.

Cinco ideas para llevarse

1

Ruta

Un workflow ejecuta una ruta; un agente *elige* la ruta.

2

Harness

El modelo decide, pero el harness hace posible y controla la ejecución.

3

Tools y skills

Las tools aportan acciones; las skills, procedimientos y criterios.

4

Loop

El loop necesita verificación, límites y condiciones de salida.

5

Autonomía

Usar la *menor autonomía suficiente* para la tarea y su riesgo.

-  Activepieces (2026). *Activepieces Documentation: Welcome*. URL: <https://www.activepieces.com/docs/overview/welcome> (visitado 27-07-2026).
-  Anthropic (2024). *Building Effective Agents*. Anthropic Engineering. URL: <https://www.anthropic.com/engineering/building-effective-agents> (visitado 27-07-2026).
-  — (2025a). *Effective Harnesses for Long-Running Agents*. Anthropic Engineering. URL: <https://www.anthropic.com/engineering/effective-harnesses-for-long-running-agents> (visitado 27-07-2026).
-  — (2025b). *Equipping Agents for the Real World with Agent Skills*. Anthropic Engineering. URL: <https://www.anthropic.com/engineering/equipping-agents-for-the-real-world-with-agent-skills> (visitado 27-07-2026).
-  — (2026). *Demystifying Evals for AI Agents*. Anthropic Engineering. URL: <https://www.anthropic.com/engineering/demystifying-evals-for-ai-agents> (visitado 27-07-2026).

-  Bender, E. M. et al. (2021). «On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?» En: *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (FAccT)*, págs. 610-623.
-  Crawford, K. (2021). *Atlas of AI: Power, Politics, and the Planetary Costs of Artificial Intelligence*. Yale University Press.
-  Floridi, L. (2023). *The Ethics of Artificial Intelligence*. Oxford University Press.
-  Google (2026). *Get Started with Workspace Studio*. URL: <https://support.google.com/workspace-studio/answer/16444479> (visitado 27-07-2026).
-  Gumloop (2026). *Gumloop Documentation: Agents and Workflows*. URL: <https://docs.gumloop.com/core-concepts/agents> (visitado 27-07-2026).
-  Mollick, E. (2024). *Co-Intelligence: Living and Working with AI*. Portfolio / Penguin.
-  Russell, S. J. y P. Norvig (2021). *Artificial Intelligence: A Modern Approach*. 4^a ed. Pearson.

-  Wooldridge, M. y N. R. Jennings (1995). «Intelligent Agents: Theory and Practice». En: *The Knowledge Engineering Review* 10.2, págs. 115-152.
-  Yao, S. et al. (2023). «ReAct: Synergizing Reasoning and Acting in Language Models». En: *International Conference on Learning Representations (ICLR)*. arXiv: 2210.03629.
-  Zdrojewski, P. D. (2026). *moodle-aula-agent: agente que construye aulas de Moodle operando el navegador*. Ver. main. URL: <https://github.com/pablozd/moodle-aula-agent> (visitado 27-07-2026).
-  Zuboff, S. (2019). *The Age of Surveillance Capitalism*. PublicAffairs.

¿Qué tarea de su práctica merece autonomía
y cuál merece solamente automatización?